Regresja liniowa

Definicja

Regresja liniowa to metoda **przewidywania wartości** szukanej zmiennej *y* (zwanej zmienną zależną lub objaśnianą) przy znanych wartościach innych zmiennych *x* (zwanych niezależnymi lub objaśniającymi).

Metoda ta zakłada, że zależność między zmienną objaśniającą a objaśnianą jest **zależnością liniową**, dlatego funkcja regresji liniowej przyjmuje postać **funkcji liniowej**:

$$y=bx+a$$

Analiza regresji liniowej ma na celu wyliczenie takich współczynników **b (ang. slope) i a (ang. intercept)**, aby funkcja **najlepiej przewidywała zmienną objaśnianą**. Linia będąca wynikiem tej funkcji nazywa się **linią najlepiej pasującą** (ang. best-fitting line) i jest **modelem regresji liniowej**.

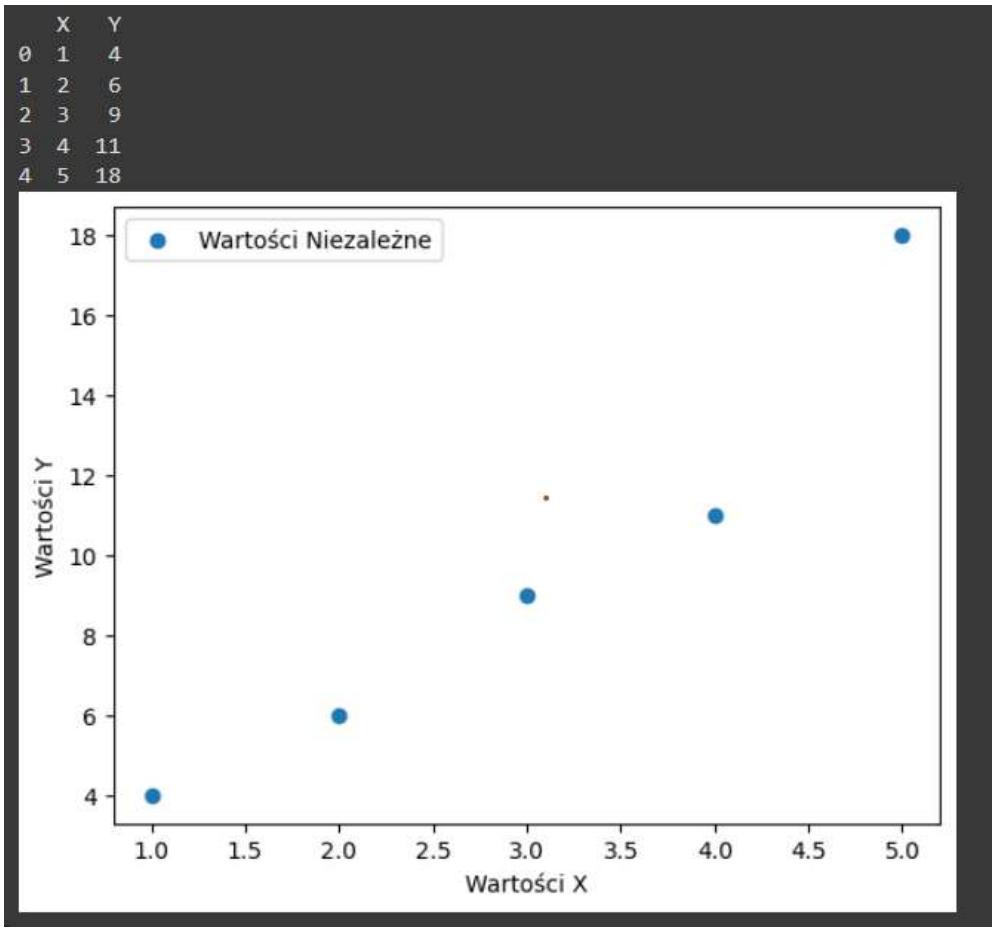

Aby wyznaczyć najlepiej pasującą linię, musimy obliczyć współczynniki b i a. Jednak zanim to zrobimy musimy przygotować sobie parę zmiennych:

- **Średnie zbiorów X i Y** (Mx, My)
- **Odchylenie standardowe (z próby) zbiorów X i Y** (Sx, Sy)
- **Współczynnik korelacji (Pearsona) zbiorów X i Y** (r)

Obliczanie średniej arytmetycznej

Średnia arytmetyczna zbioru to suma wszystkich jego elementów podzielona przez ich ilość. Określa **średnią wartość elementów danego zbioru**. Opisuje ją wzór:

$$M_A = \frac{a_1 + a_2 + \ldots + a_n}{n}$$

Więc średnie zbiorów X i Y możemy obliczyć tak:

$$Mx = \frac{1+2+3+4+5}{5} = \frac{15}{5} = 3$$
$$My = \frac{4,6,9,11,18}{5} = \frac{48}{5} = 9.6$$

Obliczanie odchylenia standardowego z próby

Odchylenie standardowe to jedna z miar zmienności zbioru. **Służy ono do estymowania o ile średnio elementy zbioru różnią się od średniej tego zbioru**. Obliczamy je za pomocą poniższego wzoru:

$$s_A = \sqrt{\frac{(a_1 - M_A)^2 + (a_2 - M_A)^2 + \ldots + (a_n - M_A)^2}{n-1}}$$

Powyższy wzór jest skomplikowany, ale bardzo łatwy do zaimplementowania, gdy znamy już **średnią zbioru**. Odchylenie standardowe policzymy tak:

$$s_X = \sqrt{\frac{(1-3)^2 + (2-3)^2 + (3-3)^2 + (4-3)^2 + (5-3)^2}{5-1}} = \sqrt{\frac{10}{4}} \approx 1.58$$
$$s_Y = \sqrt{\frac{(4-9.6)^2 + (6-9.6)^2 + (9-9.6)^2 + (11-9.6)^2 + (18-9.6)^2}{5-1}} = \sqrt{\frac{117.2}{4}} \approx 5.41$$

Powyższą funkcje odchylenia standardowego aplikujemy na zbiór X i Y.

Obliczanie współczynnika korelacji Pearsona

Współczynnik korelacji liniowej Pearsona **służy do określenia związku liczb z dwóch zbiorów**. Może przyjmować wartości od -1 do 1. Jeśli:

Współczynnik korelacji jest **większy od 0**, to znaczy, że między elementami danych zbiorów istnieje **korelacja dodatnia**. Oznacza to, że wraz ze wzrostem wartości elementów pierwszego zbioru, rosną wartości elementów drugiego zbioru. Korelacja ta jest silniejsza, gdy współczynnik ma wartość bliższą **1**.

Współczynnik korelacji jest **mniejszy od 0**, to znaczy, że między elementami danych zbiorów istnieje **korelacja ujemna**. Oznacza to, że wraz ze wzrostem wartości elementów pierwszego zbioru, maleją wartości elementów drugiego zbioru. Korelacja ta jest silniejsza, gdy współczynnik ma wartość bliższą **-1**.

Współczynnik korelacji jest **równy 0**, to znaczy, że między elementami danych zbiorów **nie ma korelacji**.

W skrócie:

- r > 0 - korelacja dodatnia
- r < 0 - korelacja ujemna
- r = 0 - brak korelacji
-

Współczynnik korelacji liniowej Pearsona opisuje wzór:

$$r_{XY} = \frac{n \times (x_1y_1 + x_2y_2 + \ldots + x_ny_n) - (x_0 + x_1 + \ldots + x_n) \times (y_0 + y_1 + \ldots + y_n)}{\sqrt{[n \times (x_0^2 + x_1^2 + \ldots + x_n^2) - (x_0 + x_1 + \ldots + x_n)^2] \times [n \times (y_0^2 + y_1^2 + \ldots + y_n^2) - (y_0 + y_1 + \ldots + y_n)^2]}}$$

Posiadając potrzebne wartości, możemy uprościć nasz wzór:

$$r_{XY} = \frac{n \times \sum x_iy_i - \sum x_i \times \sum y_i}{\sqrt{[n \times \sum x_i^2 - (\sum x_i)^2] \times [n \times \sum y_i^2 - (\sum y_i)^2]}}$$

Po podstawieniu wartości do wzoru:

$$r_{XY} = \frac{5 \times 177 - 15 \times 48}{\sqrt{[5 \times 55 - (15)^2] \times [5 \times 578 - (48)^2]}} = \frac{165}{\sqrt{29300}} \approx 0.963...$$

Obliczanie najlepiej pasującej linii

Wzór funkcji liniowej: $y=bx+a$

Obliczamy współczynniki a i b.

$$b = r \times \frac{Sy}{Sx}$$
$$a = My - b \times Mx$$

Po podstawieniu wartości:

$$b = 0.96 \times \frac{5.41}{1.58} = 3.28$$
$$a = 9.6 - 3.28 \times 3 = -0,24$$

Gdzie:

- M x/y – wyliczona wartość średnia dla x lub y
- S x/y – wyliczone odchylenie standardowe dla x lub y
- r – wyliczony współczynnik korelacji Pearsna

Otrzymana funkcja liniowa :

$$y = 3.28 * x – 0.24$$

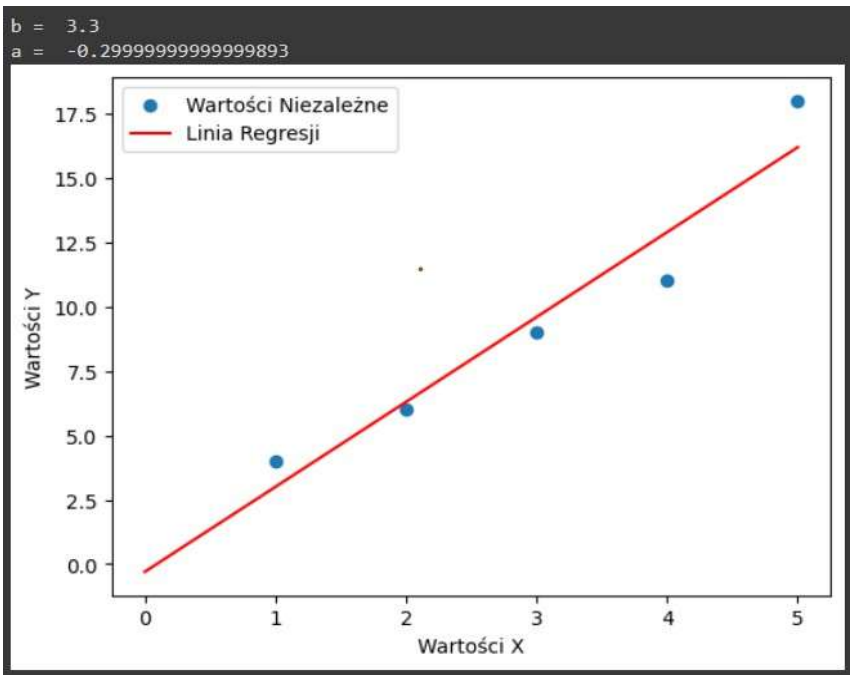

Przewidywanie przyszłych wartości

1. Dodajemy nowy element do zbioru X:
   X={1,2,3,4,5,6}
   Y={4,6,9,11,18}

2. Przewidujemy odpowiadającą wartość dla zbioru Y(podstawiamy do wzoru na funkcję liniową) :

$$y=3.3\times 6-0.29=19,51$$